

Sinapsistencia: plataforma web de mediación médico-legal con Machine Learning explicable en el sector salud del Perú

Augusto Mathias Leonardo Vasquez Requejo^{1a}, Renato German Reyes Valenzuela^{1b}

¹Escuela de Ingeniería de Sistemas y Computación, Universidad Peruana de Ciencias Aplicadas, Av. Primavera 2390, Lima, Perú

u20221a955@upc.edu.pe, u20221b471@upc.edu.pe

Palabras clave: Mediación médico-legal, Machine Learning, Inteligencia artificial explicable, Random Forest, TF-IDF, Informática en salud.

Resumen:

Los profesionales de la salud en el Perú enfrentan una exposición creciente a reclamos por mala praxis y carecen con frecuencia de acceso estructurado y oportuno a asesoría legal especializada. Este trabajo presenta Sinapsistencia, una plataforma web que conecta médicos con abogados de derecho médico mediante microservicios (Angular 21, Spring Boot 3.5, PostgreSQL y FastAPI). El sistema registra consultas médico-legales con contexto clínico simulado conforme a la Ley N.º 29733, ofrece trazabilidad documental, paneles por rol y dos componentes de ML explicable: Random Forest para riesgo legal y TF-IDF con similitud del coseno para recomendación de abogados. El modelo de riesgo se entrenó con 6 000 casos sintéticos y alcanzó precisión macro de 0,618, recall de 0,597 y F1 de 0,603. La validación incluyó cinco suites automatizadas de integración y escenarios de aceptación incrementales. La latencia media de inferencia se mantuvo por debajo de 200 ms. Los resultados muestran que un enfoque híbrido con factores XAI y respaldos de arranque en frío es viable para un MVP académico en un dominio donde la IA debe actuar como apoyo a la decisión.

1 INTRODUCCIÓN

Los conflictos por mala praxis y negligencia médica en el Perú son cada vez más visibles a través de la supervisión institucional y los canales de defensa de derechos en salud. SUSALUD reportó más de 163 000 atenciones sobre derechos en salud solo en 2024, lo que refleja una demanda sostenida de mecanismos formales de recurso. Sin embargo, los médicos recurren con frecuencia a redes informales para obtener orientación legal, con demoras estimadas de 48 a 72 horas y escasa trazabilidad auditable (Miziara y Miziara, 2022; Tumelty, 2023).

El problema es relevante porque la demora en la orientación legal incrementa la vulnerabilidad profesional, favorece la medicina defensiva y dificulta la estructuración temprana del caso (Gunenc et al., 2024; Rowland et al., 2022). Las plataformas digitales podrían mejorar la mediación, pero los enfoques ingenuos fallan por tres razones: (i) los datos médico-legales son sensibles y regulados; (ii) las recomendaciones de caja negra son éticamente inaceptables en contextos de responsabilidad (Jones et al., 2023; Scott et al., 2024); y (iii) las condiciones de arranque en frío limitan el filtrado colaborativo cuando faltan historiales densos de interacción médico-abogado.

Las soluciones previas abordan fragmentos del problema—historias clínicas electrónicas, marketplaces legales genéricos o sistemas de apoyo a la decisión clínica—, pero no la mediación integrada médico-abogado con priorización explicable bajo gobernanza por roles. Sinapsistencia se diferencia al combinar (1) contexto de caso simulado no identificable, (2) separación en microservicio de la inferencia ML, (3) persistencia de explicaciones XAI y (4) emparejamiento de respaldo por especialidad cuando el servicio ML no está disponible.

Los componentes clave del enfoque son: una aplicación web con tres portales (médico, abogado y administrador); una API Spring Boot con reglas de ownership en la capa de servicio; un servicio FastAPI que implementa puntuación de riesgo con Random Forest y ranking de abogados con TF-IDF; y una bitácora de auditoría para acciones críticas. Las limitaciones actuales incluyen datos de entrenamiento sintéticos, validación piloto sin registros reales de pacientes y la ejecución pendiente a gran escala del plan académico de 90 casos de prueba.

El resto del artículo se organiza así: la sección 2 revisa trabajos relacionados; la sección 3 describe la arquitectura y los algoritmos propuestos; la sección 4 explica la metodología de validación; la sección 5 presenta los resultados; y la sección 6 concluye con perspectivas futuras.

2 TRABAJOS RELACIONADOS

La investigación sobre riesgo médico-legal, apoyo a la decisión asistido por IA y sistemas de recomendación fundamenta Sinapsistencia. Agrupamos los trabajos previos en tres líneas.

Negligencia médica y responsabilidad digital.

Miziara y Miziara (2022) revisan errores médicos, negligencia y medicina defensiva, destacando la documentación y la comunicación como puntos recurrentes de falla. Rowland et al. (2022) analizan riesgos de mala praxis en salud digital, enfatizando trazabilidad y rendición de cuentas. Wong et al. (2021) estudian reclamos en servicios de urgencia, mostrando que los problemas procedimentales y documentales dominan los patrones de litigio. Estos estudios justifican la captura estructurada de casos y el versionado documental, pero no ofrecen flujos integrados de mediación entre clínicos y abogados.

IA confiable en contextos clínicos y legales.

Jones et al. (2023) reportan preocupaciones de los clínicos sobre confianza y responsabilidad al usar apoyo a la decisión con IA. Wang et al. (2023) revisan sistemáticamente el diseño centrado en el humano para sistemas clínicos con IA, recomendando transparencia y límites explícitos. Scott et al. (2024) señalan barreras de adopción cuando faltan explicaciones. Nuestra plataforma aborda esta brecha al persistir factores de riesgo derivados de la importancia de características y al mostrar mensajes de advertencia no deterministas en la interfaz.

Técnicas de emparejamiento y modelado de riesgo.

Manning et al. (2008) y Ricci et al. (2015) establecen TF-IDF y la recomendación basada en contenido como estrategias efectivas de arranque en frío, relevantes para el emparejamiento médico-abogado sin historiales densos. Los clasificadores Random Forest permanecen como línea base robusta para puntuación tabular de riesgo con contribuciones interpretables (Aggarwal, 2016). A diferencia de marketplaces legales previos, Sinapsistencia acopla ambas técnicas en un flujo específico de salud con datos simulados alineados a la normativa peruana de privacidad (Congreso de la República del Perú, 2011).

3 SOLUCIÓN PROPUESTA

Sinapsistencia sigue una arquitectura de microservicios desacoplada. El frontend Angular 21 consume APIs REST de un backend Spring Boot 3.5 (Java 21) protegido con JWT y control de acceso basado en roles. PostgreSQL 16 almacena los datos operativos y las migraciones Flyway versionan el esquema. Un servicio FastAPI dedicado aloja los modelos ML, invocado por el backend mediante un proxy HTTP con tiempo de espera de 5 segundos y degradación controlada.

3.1 Arquitectura del sistema

El portal médico permite crear consultas con contexto clínico-legal simulado (edad referencial, área médica, resumen, factores relevantes) sin datos identificables del paciente. El portal del abogado lista casos pendientes y solicitudes de contacto pertinentes. El portal administrador gestiona usuarios, bitácora de auditoría, métricas ML y reportes resumen. Las reglas de ownership impiden que un médico acceda a consultas de sus pares; se aplican en la capa de servicio y se validan con pruebas de integración automatizadas.

3.2 Modelo de evaluación de riesgo (Random Forest)

El módulo de riesgo predice `risk_score` (0–1) y `risk_level` (bajo, moderado, alto, crítico) a partir de características estructuradas: especialidad médica, complejidad del procedimiento, prioridad, completitud de documentación, consentimiento informado, quejas previas y días desde el incidente. Los datos de entrenamiento comprenden 6 000 filas sintéticas generadas por reglas de negocio más ruido gaussiano para evitar memorización trivial. Un `RandomForestClassifier` (200 árboles) y un `RandomForestRegressor` comparten el mismo espacio de características preprocesadas (one-hot de especialidad, ordinal de complejidad/prioridad). La explicabilidad combina importancia global de características con valores normalizados del caso para producir `risk_factors` mostrados como contexto de apoyo.

3.3 Emparejamiento médico-abogado (TF-IDF + similitud del coseno)

Los perfiles de abogados se vectorizan con `TfidfVectorizer` sobre especialidades legales, áreas médicas de interés y texto biográfico. Las consultas del médico, construidas a partir de especialidad y contexto del caso, se comparan mediante similitud del coseno. Los resultados incluyen `content_score`, especialidades coincidentes y razones en lenguaje natural.

Cuando el servicio ML no está disponible, el backend aplica un respaldo de arranque en frío que ordena abogados por coincidencia de área médica.

3.4 Contrato de API

FastAPI expone GET /health, GET /api/v1/model/info, POST /api/v1/risk-assessment y POST /api/v1/recommendations. Spring Boot actúa como proxy de estos endpoints y normaliza las respuestas a camelCase para el frontend. Los niveles de riesgo alto o crítico pueden disparar notificaciones opcionales fire-and-forget hacia un webhook de automatización externo.

4 EXPERIMENTOS Y VALIDACIÓN

La validación siguió cuatro frentes alineados al plan de calidad del proyecto: (1) evaluación offline del ML, (2) pruebas de integración del backend, (3) verificación de compilación del frontend y (4) escenarios funcionales incrementales del catálogo académico de pruebas.

4.1 Protocolo experimental para ML

El conjunto sintético se dividió 80/20 con estratificación sobre risk_level. Las métricas se reportan sobre la partición de prueba. El emparejamiento se evaluó cualitativamente en escenarios demo con un corpus de ocho perfiles de abogados alineados a identificadores de base de datos. Todos los experimentos se ejecutaron en una estación de desarrollo con Python 3.12, scikit-learn 1.5.2 y FastAPI 0.115.0.

4.2 Pruebas de integración de software

Cinco suites JUnit se ejecutaron contra PostgreSQL con Testcontainers: arranque de contexto, enforcement de ownership, subrecursos de consulta (timeline y respuestas legales), flujos de funcionalidades (cambio de contraseña, transiciones de estado, reportes admin) y carga/descarga de documentos. La compilación de producción del frontend (ng build) verificó la integridad de los portales médico, abogado y administrador.

5 RESULTADOS

5.1 Resultados cuantitativos

La Tabla 1 resume el desempeño del Random Forest en el conjunto de prueba retenido (versión del modelo rf-v1).

Métrica	Valor
Precisión (macro)	0,6179
Recall (macro)	0,5973
F1-score (macro)	0,6034
Tamaño del dataset	6 000 casos sintéticos
Latencia media de inferencia (local)	~120 ms

Tabla 1: Métricas de evaluación del clasificador de riesgo.

Las cinco suites de integración del backend pasaron con éxito del 100 % usando PostgreSQL con Docker. Las operaciones REST críticas—incluidos login, creación de consulta, proxy de matching y reporte administrativo—completaron en menos de 2 segundos en mediciones locales, cumpliendo el indicador de tiempo de respuesta del OE3 para el alcance del MVP.

5.2 Resultados cualitativos

Las demostraciones de extremo a extremo confirmaron: (i) navegación por rol en los tres portales; (ii) registro de consultas con contexto simulado; (iii) recomendaciones de abogados con razones XAI; (iv) clasificaciones ML persistidas recuperables desde la API; y (v) advertencias visibles sobre el uso de IA. Los abogados recibieron casos no asignados pertinentes filtrados por áreas médicas declaradas. Estas observaciones respaldan la viabilidad de una evaluación piloto académica en la Clínica SANNA «El Golf» usando únicamente escenarios simulados.

6 CONCLUSIONES

Este artículo presentó Sinapsistencia, una plataforma de mediación médico-legal que integra flujos estructurados, auditabilidad y Machine Learning explicable para el contexto de salud peruano. El diseño híbrido—Random Forest para

puntuación de riesgo y TF-IDF para emparejamiento médico-abogado—aborda restricciones de arranque en frío manteniendo una latencia de inferencia adecuada para uso interactivo.

Los resultados sobre datos sintéticos demuestran un desempeño de clasificación moderado ($F1 \approx 0,60$) e integración exitosa del software entre frontend, backend, base de datos y servicio ML. El sistema trata explícitamente las salidas de IA como apoyo no determinista, alineado a requisitos éticos en dominios sensibles a la responsabilidad.

El trabajo futuro incluye: (i) ampliar el corpus de abogados y retroalimentación piloto sin datos identificables; (ii) evaluación cuantitativa del emparejamiento hacia una meta de pertinencia $\geq 70\%$ en el top-3; (iii) despliegue en la nube para entornos de demostración; (iv) ejecución del plan completo de 90 casos de prueba funcionales; y (v) evaluación de usabilidad con la Escala de Usabilidad del Sistema (SUS) en TP2.

AGRADECIMIENTOS

Agradecemos a la Escuela de Ingeniería de Sistemas y Computación de la Universidad Peruana de Ciencias Aplicadas por el apoyo académico; a nuestros asesores Jymmy Stewart Dextre Alarcón y Jorge Enrique Polo Martínez por la orientación metodológica; y a la Clínica SANNA «El Golf» por la colaboración institucional en el contexto de validación simulada.

REFERENCIAS

- Aggarwal, C. C. (2016). *Recommender systems: The textbook*. Springer.
- Congreso de la República del Perú. (2011). Ley N.º 29733, Ley de Protección de Datos Personales. El Peruano.
- Gunenc, O., Kulhan, N. G., Bayman, M. G., Celik, C., Bilgi, A., Colluoglu, C., & Kulhan, M. (2024). Medical malpractice stress syndrome and defensive medicine in obstetricians and gynecologists in Turkey. *International Journal of Clinical Practice*, 2024, Article 8226403. <https://doi.org/10.1155/2024/8226403>
- Jones, C., Thornton, J., & Wyatt, J. C. (2023). Artificial intelligence and clinical decision support: Clinicians' perspectives on trust, trustworthiness, and liability. *Medical Law Review*, 31(4), 501–520. <https://doi.org/10.1093/medlaw/fwad013>
- Manning, C. D., Raghavan, P., & Schütze, H. (2008). *Introduction to information retrieval*. Cambridge University Press.
- Miziara, I. D., & Miziara, C. S. M. G. (2022). Medical errors, medical negligence and defensive medicine: A narrative review. *Clinics*, 77, Article 100053. <https://doi.org/10.1016/j.clinsp.2022.100053>
- Ricci, F., Rokach, L., & Shapira, B. (2015). *Recommender systems handbook* (2nd ed.). Springer.
- Rowland, S. P., Fitzgerald, J. E., Lungren, M., Lee, E. (H.), Harned, Z., & McGregor, A. H. (2022). Digital health technology-specific risks for medical malpractice liability. *NPJ Digital Medicine*, 5, Article 157. <https://doi.org/10.1038/s41746-022-00698-3>
- Scott, I. A., van der Vegt, A., Lane, P., McPhail, S., & Magrabi, F. (2024). Achieving large-scale clinician adoption of AI-enabled decision support. *BMJ Health & Care Informatics*, 31, Article e100971. <https://doi.org/10.1136/bmjhci-2023-100971>
- Superintendencia Nacional de Salud. (2025). SUSALUD brindó más de 163 mil atenciones sobre derechos en salud durante el 2024. Gobierno del Perú.
- Tumelty, M.-E. (2023). Plaintiff aims in medical negligence disputes: Limitations of an adversarial system. *Medical Law Review*, 31(2), 226–246. <https://doi.org/10.1093/medlaw/fvac037>
- Wang, L., Zhang, Z., Wang, D., Cao, W., Zhou, X., Zhang, P., Liu, J., Fan, X., & Tian, F. (2023). Human-centered design and evaluation of AI-empowered clinical decision support systems: A systematic review. *Frontiers in Computer Science*, 5, Article 1187299. <https://doi.org/10.3389/fcomp.2023.1187299>
- Wong, K. E., Parikh, P. D., Miller, K. C., & Zonfrillo, M. R. (2021). Emergency department and urgent care medical malpractice claims 2001–15. *Western Journal of Emergency Medicine*, 22(2), 333–338. <https://doi.org/10.5811/westjem.2020.9.48845>